罗森予
202401093034

题目：基于自然语言处理的 AI 取代就业网络舆情分析——以知乎、微博、小红书与豆瓣文本为例

学年学期：2025—2026 学年春季学期

课程名称：自然语言处理

课程编号：2011030299

课程序号：01

任课教师：史博文

姓　　名：罗森予

学　　号：202401093034

评分区域（由阅卷老师填写）：

结课成绩：

总评成绩：

提交时间：2026 年 7 月 22 日

罗森予
202401093034

目录

一、研究背景与问题提出 4
二、数据来源与研究方法 4
2.1 数据获取过程 4
2.2 数据预处理与自然语言处理流程 5
2.3 Python 实现过程 5
三、高频词呈现出“技术-就业-自我”的核心框架 7
四、平台情绪总体偏积极，但豆瓣消极比例最高 8
五、LDA 主题显示 AI 就业议题与职场生活压力并存 9
六、讨论：AI 就业舆情中的传播机制 10
七、结论与不足 10
参考文献 11

罗森予
202401093034

关键词： AI 取代就业；自然语言处理；Vibe Coding；情感分析；LDA 主题模型；网络舆情；社交媒体

摘要： 随着生成式人工智能的快速发展，“AI 是否会取代人类就业”成为社交媒体中的热点议题。本文以知乎、微博、小红书和豆瓣四个国内主流平台关于“AI 取代就业”的相关文本为研究对象，共获取并清洗 1800 条有效数据。基于 Python，结合 Vibe Coding 开发方式，利用 Codex 和 Trae 辅助完成数据采集与程序开发，采用 jieba 分词、词频统计、SnowNLP 情感分析和 LDA 主题模型等自然语言处理方法，对网络文本进行分析。研究发现，公众讨论主要围绕“AI—取代—就业—焦虑”等关键词展开，不同平台在情绪表达和主题分布上存在一定差异。结合传播学相关理论进行分析，可以看出平台传播环境对公众技术风险认知具有重要影响。本研究展示了自然语言处理方法在网络舆情分析中的应用，为 AI 就业议题研究提供了数据支持，也为课程实践提供了参考。

Keywords: AI and Employment; Natural Language Processing; Vibe Coding; Sentiment Analysis; LDA Topic Model

Abstract：With the rapid development of generative artificial intelligence, whether AI will replace human jobs has become a hot topic on social media. This paper collected 1,800 valid texts from Zhihu, Weibo, Xiaohongshu and Douban. Based on Python and Vibe Coding, NLP methods including word frequency analysis, SnowNLP sentiment analysis and LDA topic modeling were used to analyze public discussions. The results show that different platforms present different emotional tendencies and topic distributions, reflecting the influence of social media on public perceptions of AI and employment.

罗森予
202401093034

一、研究背景与问题提出

近几年，生成式人工智能、自动化办公工具和算法推荐系统快速进入日常工作场景，“AI 会不会取代人类工作”成为社交媒体中的高频公共议题。这个议题并不只是技术问题，也是一种传播问题：公众如何命名风险、平台如何放大焦虑、不同社群如何形成关于未来工作的共同想象，都会影响人们理解技术变迁的方式。议程设置理论指出，媒介不一定直接告诉人们“怎样想”，但会显著影响人们“想什么”[1]。当“AI”“取代”“失业”“焦虑”等词语在网络讨论中持续出现时，技术进步便被置于就业安全、阶层流动和个体竞争力的解释框架中。

本报告以“AI 取代就业”为核心主题，整理并合并知乎、微博、小红书与豆瓣等平台相关文本，共得到 1800 条有效文本。其中知乎、微博、小红书各 500 条，豆瓣 300 条。报告使用中文分词、停用词过滤、词频统计、SnowNLP 情感分析与 LDA 主题模型进行文本挖掘，生成可视化图表，并结合框架理论、风险传播、技术想象、沉默的螺旋和两级传播等传播学理论讨论结果。

研究问题包括：

1、公众讨论“AI 取代就业”时最常使用哪些关键词？

2、同平台的情绪倾向是否存在差异？

3、主题模型呈现出哪些议题结构？第四，这些结果如何解释平台化传播环境下的技术风险认知。

二、数据来源与研究方法

2.1 数据获取过程

为了保证数据具有一定代表性，本研究选择知乎、微博、小红书和豆瓣四个国内主流社交平台作为数据来源。这四个平台具有不同的用户群体和内容生态：知乎以知识问答和观点讨论为主，微博具有较强的公共事件传播属性，小红书以经验分享和生活方式内容为主，豆瓣则聚集了大量关于学习、职场和生活经验的讨论。因此，将四个平台的数据进行综合分析，可以更全面地观察公众对于“AI 取代就业”这一议题的讨论特点。

在数据采集过程中，本研究首先确定关键词，包括“AI 取代就业”“AI 失业”“人工智能就业”“AI 会取代人类工作”“AI 裁员”等多个检索词，并分别在四个平台进行搜索。为了减少单个平台算法推荐造成的数据偏差，同一关键词在不同排序方式（综合排序、最新排序、热门排序）下均进行了检索。

数据抓取原计划全部借助 codex 的 ChatGPT5.5 模型，在过去的作业尝试中该工具都极其适合 vibe coding，但是由于期末大作业体量比较大，经过 2 轮爬取之后，获取了

罗森予
202401093034
清洗后的豆瓣数据，codex 免费版额度就用尽了，ChatGPT 在大陆地区及港澳地区充 plus 版具有比较大的困难。于是小红书、微博、知乎的爬取数据均采用 Trae 进行，Trae 在运行速度和质量上相对较低，但是也能满足数据爬取与绘图的需求。

通过自然语言向 Codex 描述数据采集需求，由 AI 生成基础爬虫程序，包括页面访问、内容解析、翻页逻辑以及 CSV 文件保存等功能。由于不同平台网页结构存在差异，在程序运行过程中不断结合报错信息进行修改，例如调整请求头（User-Agent）、补充 Cookie 信息、修改 XPath 或 CSS Selector 定位方式、增加异常处理以及请求间隔时间等，使程序能够稳定完成数据采集。整个过程中，Trae 主要用于辅助代码调试、错误定位和程序优化，而最终程序均经过本人实际运行和验证。

在实际采集过程中，也遇到了一些问题。尤其是在获取 cookie 时，在网页需要 fn+F12 人工查找 cookie，这一步比较难执行，除此之外，部分平台存在访问频率限制，需要通过设置请求间隔时间、随机 User-Agent 降低请求频率；部分帖子内容因删除、权限限制等原因无法获取，因此进行了人工筛查。最终共获得原始文本约 2200 余条，经过去重、清洗和异常数据删除后，保留 1800 条有效文本进入后续分析。

2.2 数据预处理与自然语言处理流程

网络平台获取的原始文本通常包含大量干扰信息，因此正式分析之前需要进行数据预处理。同样采用 Vibe Coding 的开发方式，通过自然语言描述需求，由 Codex 和 Trae 辅助生成数据清洗程序，再结合运行结果不断修改代码。

首先，对原始文本进行格式清洗。利用 Python 删除网页链接、HTML 标签、特殊符号、多余空格以及部分无法识别的字符，仅保留中文、英文、数字及少量具有分析意义的标点符号，以减少无效信息对分析结果的影响。其次，对数据进行重复检测和异常数据筛选。由于同一内容可能存在重复发布、转发或复制现象，因此利用 Python 完成文本去重，并人工检查明显无关内容，如广告、营销信息、仅包含图片说明或无实际文本内容的数据，进一步提高数据质量。随后，采用 jieba 进行中文自动分词。完成分词后，进一步利用停用词词典删除“我们”“这个”“那个”“就是”“然后”等大量无实际语义的信息词，并根据实验过程中观察到的结果不断调整停用词列表，使保留下来的词语能够更加准确地反映公众讨论重点。

经过预处理后，全部文本统一保存为 cleaned 文件，并生成包含平台来源（platform）、原始文本（raw_text）、清洗后文本（cleaned_text）、发布时间（publish_time）以及互动量（engagement）等字段的数据集，为词频统计、情感分析和主题模型分析提供统一的数据输入。

2.3 Python 实现过程

本研究全部分析流程基于 Python 语言完成，并结合 Codex 和 Trae 进行 AI 辅助开发。整个实验遵循“需求描述—AI 生成代码—人工调试—结果验证”的 Vibe Coding 流

罗森予
202401093034
程，在保证分析效率的同时，也进一步理解了自然语言处理算法的实现过程。

数据处理部分主要使用 pandas 完成 CSV 文件读取、数据整理、字段统计以及平台分类等工作；中文分词采用 jieba 实现，并统计高频词，为后续词频分析提供基础数据。情感分析部分采用 SnowNLP 完成。程序首先读取预处理后的文本，对每条文本计算情感得分，再根据设定阈值划分为积极、中立和消极三类，并统计四个平台不同情绪所占比例。随后利用 matplotlib 绘制平台情绪分布图，对不同平台之间的情绪特点进行比较分析。主题分析部分采用 LDA 主题模型实现。程序首先根据分词结果建立 Dictionary 词典，再训练 LDA 模型，对全部文本自动提取潜在主题及对应关键词。为了获得较好的主题区分效果，本研究在实验过程中多次调整主题数量和模型参数，对不同结果进行比较，最终确定四个主题作为本研究的分析结果。

图表绘制同样通过 Python 自动完成，包括高频词统计图、情感分析图以及 LDA 主题分布图。所有程序均经过多次运行和验证，确保结果具有较好的稳定性和可重复性。方法上，情感分析用于比较不同平台的积极、中立、消极表达比例；LDA 主题模型用于从词项共现中抽取潜在主题。LDA 模型唐晓波,向坤指出适合在无监督条件下发现大规模文本集合中的潜在主题分布[8]。情感分析方面，韩忠明,李梦琪,刘雯说明，情感倾向识别可以把文本从“说了什么”进一步推进到“以什么态度说”[9]；Liu 也指出，意见挖掘适合分析用户生成内容中的评价、情绪和立场[10]。不过，中文社交媒体文本存在反讽、夸张、表情缺失和语境依赖等问题，因此本报告把情感结果视为一种辅助解释，而不是绝对测量。

平台	文本量	说明
知乎	500	偏向问题讨论和观点表达，适合观察理性化解释框架
微博	500	偏向短文本和话题标签，适合观察即时情绪与公共议题扩散
小红书	500	偏向经验叙事和生活化表达，适合观察个体化应对策略
豆瓣	300	偏向职场生活文本，适合补充工作压力、老板、考研等相邻语境

罗森予
202401093034

三、高频词呈现出“技术-就业-自我”的核心框架

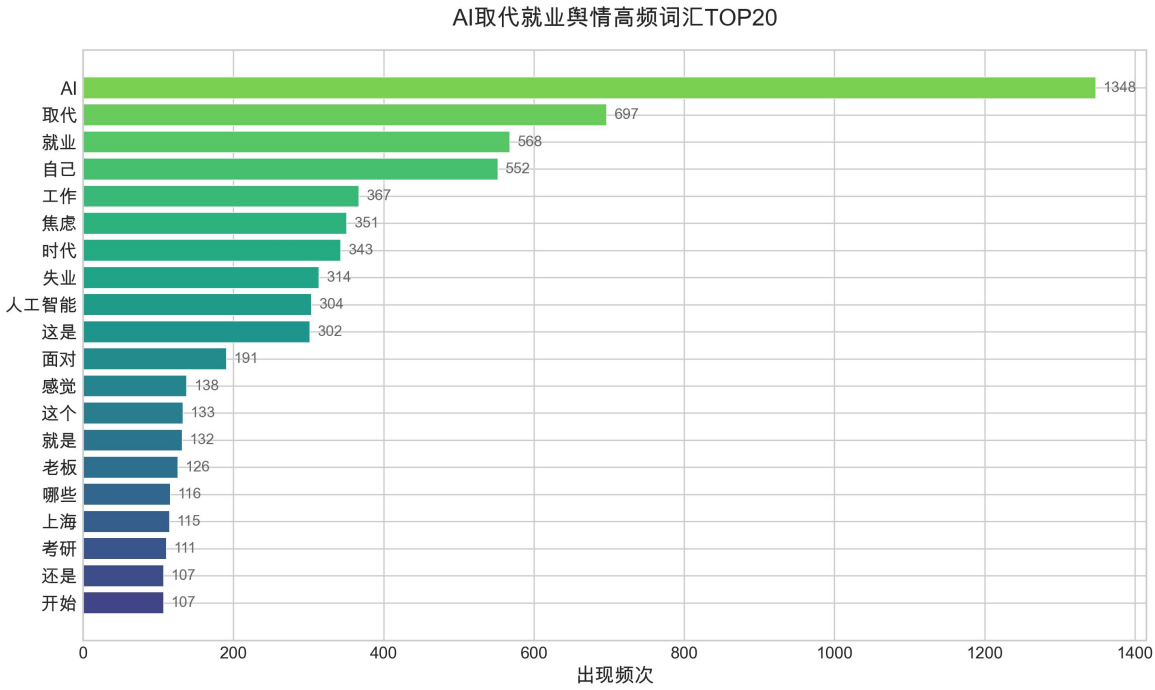


图 1 AI 取代就业舆情高频词汇 TOP20

图 1 显示，最高频词为“AI”（1348 次），随后是“取代”（697 次）、“就业”（568 次）、“自己”（552 次）、“工作”（367 次）、“焦虑”（351 次）、“时代”（343 次）、“失业”（314 次）和“人工智能”（304 次）。这些词构成了一个非常清晰的解释链条：技术被命名为“AI/人工智能”，社会后果被命名为“取代/就业/失业”，主体位置则落在“自己/工作/焦虑”。换言之，公众并没有把 AI 仅仅理解为抽象技术，而是把它直接嵌入个人职业安全和生活规划之中。

从框架理论看，新闻和社交媒体文本会通过选择、强调、排除和解释来组织现实，使某些问题定义和因果解释更突出[2]。本数据中的词频结构说明，“AI 取代就业”主要被框架化为一种劳动风险，而不是单纯的产业升级叙事。尤其是“自己”排在第四位，说明讨论并非只围绕宏观经济或企业效率，而是强烈指向个体身份与生存处境。张志成认为，社会现实是在日常互动和意义生产中被建构出来的[7]。在此意义上，公众反复使用“焦虑”“失业”“竞争力”“应对”等词语，本身就在建构一种关于 AI 时代的社会现实：每个人都可能被要求重新评估自身价值。

值得注意的是，“老板”“考研”“上海”等词也进入前 20。它们看似偏离 AI 主题，但实际上揭示了就业焦虑的相邻语境：一方面，AI 取代劳动的讨论与职场权力关系、管理压力和薪酬不稳定相互叠加；另一方面，考研、城市竞争和职业选择成为年轻人逃离或应对不确定性的常见路径。这说明公众对 AI 的恐惧并不是凭空出现，而是与既有的职场结构、教育竞争和城市生活压力相互耦合。Frey 和 Osborne 关于职业自动化风险的研究曾指出，不同职业面对技术替代的脆弱性并不相同；社交媒体讨论则把这种结构性风险转化为可以被个人感知的生活压力。

罗森予
202401093034

四、平台情绪总体偏积极，但豆瓣消极比例最高

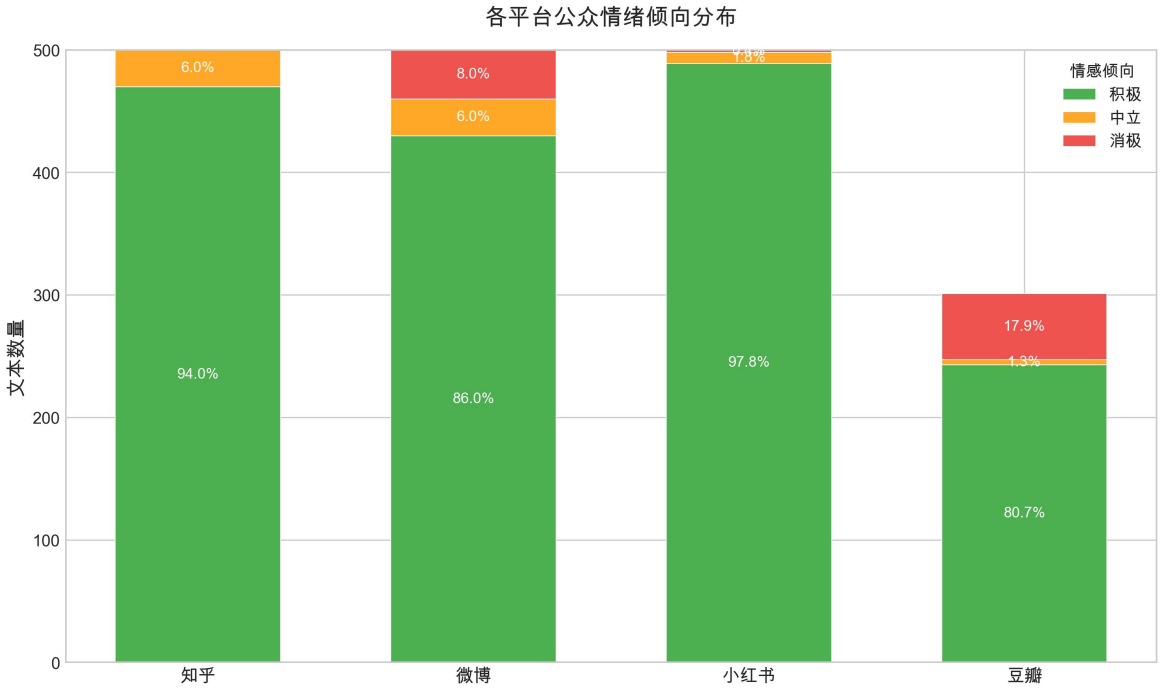


图 2 各平台公众情绪倾向分布

图 2 展示了四个平台的情感分布。知乎积极文本占 94.0%，中立占 6.0%；微博积极占 86.0%，中立占 6.0%，消极占 8.0%；小红书积极占 97.8%，中立占 1.8%，消极占 0.4%；豆瓣积极占 80.7%，中立占 1.3%，消极占 17.9%。从整体看，积极表达占比较高，这与文本中大量“如何应对”“保持竞争力”“培养技能”“拥抱变化”等词句有关。但消极比例在豆瓣明显更高，说明职场生活语境中的压力、老板、考研、身体不适等内容，会把 AI 议题拉向更具体的劳动困境。

这一结果可以用风险传播理论解释。风险并不是只由客观概率决定，也受到传播渠道、社会信任、群体经验和情绪共鸣的影响。社交媒体中的 AI 就业风险常常以短句、标签和个人故事传播，使抽象的技术不确定性转化为“我会不会失业”“我的专业还有没有价值”这样的亲身问题。微博的消极比例高于知乎和小红书，可能与微博的公共事件扩散机制有关：微博的热搜、话题标签和转发结构更容易形成事件化表达，也更容易把担忧凝聚为公共情绪。两级传播理论指出，意见领袖会在信息扩散中发挥中介作用[4]；在微博等平台，行业博主、职场账号和科技媒体的表达可能进一步影响普通用户对 AI 风险的判断。

小红书积极比例最高，可以理解为平台文化对表达方式的塑造。小红书常见的内容形式是经验分享、技能清单、学习路径和自我提升叙事，因此即使面对 AI 替代风险，文本也倾向于转化为“如何准备”“如何转型”“如何提升效率”的行动方案。这与创新扩散理论相呼应：新技术的采纳往往受到相对优势、复杂性、可试用性和可观察性等因素影响[3]。当平台内容把 AI 包装成可学习、可使用、可变现的工具时，风险感会被部分转译为机会感。

罗森予
202401093034

但是，情感分析结果也需要谨慎理解。SnowNLP 对中文短文本具有便利性，但对讽刺、反问和语境转换的识别有限。例如“AI 真的太强了，我饭碗没了”可能既有惊叹也有焦虑，机器分类未必能完全捕捉复杂情绪。因此，本文更关注跨平台差异和总体趋势，而不是把每一条文本的情感标签视为完全准确。

五、LDA 主题显示 AI 就业议题与职场生活压力并存

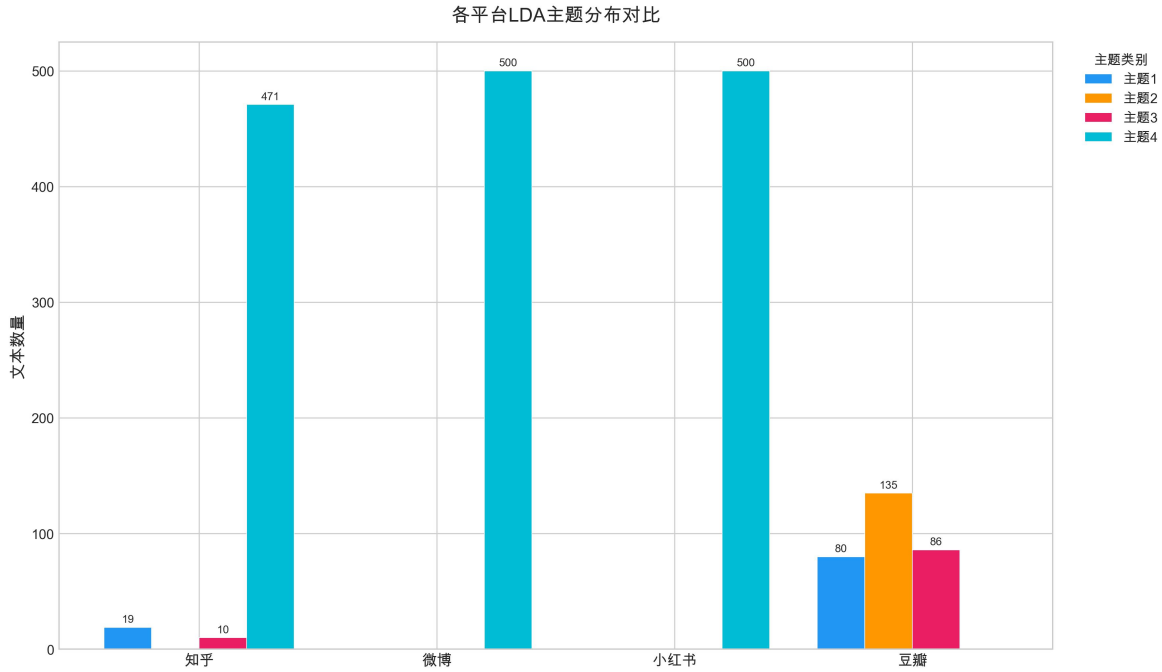


图 3 各平台 LDA 主题分布对比

LDA 模型抽取出四个主题。主题 1 关键词为“实习、面试、职场、海外、课程、学员、自己、托福”，可概括为职业准备与教育培训；主题 2 关键词为“自己、上海、医生、感觉、检查、屁股、然后、裤子”，更接近生活经验与身体化压力叙事；主题 3 关键词为“自己、老板、考研、就是、员工、不要、这个、对方”，可概括为职场关系与转向选择；主题 4 关键词为“ai、取代、就业、焦虑、工作、时代、失业、人工智能”，是最直接的 AI 就业焦虑主题。

平台分布上，微博和小红书文本全部归入主题 4，知乎有 94.2%归入主题 4，说明这三个平台围绕“AI 取代就业”的主题集中度较高。豆瓣则没有进入主题 4，而是在主题 1、主题 2、主题 3 之间分布：主题 1 占 26.6%，主题 2 占 44.9%，主题 3 占 28.6%。这说明豆瓣文本更像是提供了广义职场压力和生活困境的背景材料，而不是直接讨论 AI 替代。对于报告解释而言，这一点反而有价值：AI 就业焦虑并不是孤立情绪，它会与既有职场不满、教育焦虑、城市压力和身体疲惫相互连接。

从传播学角度看，这体现了“框架竞争”。同一个技术议题可以被不同平台连接到不同意义系统：知乎更容易进入理性问答和职业规划框架，微博更容易进入公共情绪和热点框架，小红书更容易进入经验分享和自我提升框架，豆瓣则把技术风险放入更宽的工

罗森予
202401093034
作生活叙事。Noelle-Neumann 的沉默的螺旋理论认为，个体会感知舆论气候，并据此决定是否表达自己的意见[5]。当某个平台形成“要积极学习 AI”的主流表达时，消极、无力或抵触的声音可能被压低；而在更偏生活吐槽的平台中，负面情绪则更容易被表达出来。

同时，张智鹏的理论提醒我们，长期接触某类媒介叙事会影响人们对现实的总体判断[6]。如果用户长期看到“AI 淘汰岗位”“普通人必须转型”“不会 AI 就落后”等表达，即使现实中的职业替代并未立刻发生，也可能形成一种提前到来的危机感。这种危机感会推动学习和适应，也可能造成不必要的焦虑和自我贬值。张洋,廖怀远强调，数字技术会提高生产力，但收益分配和技能转换并不会自动公平发生[12]。因此，传播分析不能只评价公众是否“过度焦虑”，还要看到焦虑背后的制度性不确定。

六、讨论：AI 就业舆情中的传播机制

议程设置机制使 AI 就业风险成为可见议题。高频词显示，“AI 取代就业”的讨论已经形成稳定的词汇组合。公众在平台上不断重复这些词语，会使就业风险在注意力市场中保持高曝光。即使具体行业、岗位和技术能力存在差异，平台化传播也会把复杂问题压缩为醒目的公共议题。

框架机制决定公众如何理解技术。数据中的“取代”“失业”“焦虑”说明替代框架非常强；但“小红书积极比例高”又说明平台也能把同一议题改写为学习框架、机会框架和个人成长框架。传播中的意义并非固定，它取决于平台机制、文本体裁和用户社群。

情绪传播推动议题扩散。AI 就业讨论往往不是冷静的技术评估，而是混合了恐惧、期待、羡慕和自我怀疑。情绪具有很强的可传播性，尤其在短文本平台中，焦虑和希望都容易被压缩为可转发的句子。微博的消极比例高于知乎、小红书，提示我们不同平台的传播结构会改变情绪表达的强度。

个体化叙事把结构问题转化为个人责任。许多文本把应对路径落在“提升技能”“保持竞争力”“拥抱变化”上，这当然具有实践意义，但也可能遮蔽更深层的劳动制度问题，例如岗位转型成本、教育资源差异、企业裁员逻辑和社会保障不足。传播学分析需要在个人努力叙事之外，继续追问谁在定义风险，谁承担成本，谁从技术效率中获益。

七、结论与不足

本研究基于 1800 条跨平台文本，使用自然语言处理方法分析了“AI 取代就业”舆情。词频分析表明，公众讨论围绕“AI-取代-就业-自己-焦虑”形成核心词汇链条，说明该议题已经被高度个人化和风险化。情感分析显示，各平台总体积极表达较多，但豆瓣消极比例最高，微博也呈现一定焦虑表达。LDA 主题模型进一步显示，AI 就业焦虑主题在知乎、微博、小红书中高度集中，而豆瓣更多呈现职场生活压力、教育选择和身体经验等相邻主题。

罗森予
202401093034

结合传播学理论可以看到，AI 就业舆情不是单纯的技术反应，而是议程设置、框架建构、平台文化、意见领袖和情绪扩散共同作用的结果。公众对 AI 的理解，一方面来自技术本身的快速发展，另一方面也来自社交媒体持续提供的风险想象和应对脚本。未来研究可以进一步扩大抓取数据规模，引入人工标注来校验情感分析准确性，并比较不同时间节点上 AI 就业讨论如何随政策、技术产品和就业市场变化而变化。

参考文献

[1] McCombs M E, Shaw D L. The agenda-setting function of mass media[J]. Public opinion quarterly, 1972, 36(2): 176-187.

[2] Entman R M. Framing: Towards clarification of a fractured paradigm[J]. McQuail's reader in mass communication theory, 1993, 390: 397.

[3] 叶柳江,方兴东.DeepSeek 浪潮形成的宏观与微观机制研究——基于社交媒体接触对 DeepSeek 使用意愿影响的量化分析[J]. 青年记者,2025,(4)50-58.DOI:10.15997/j.cnki.qnjz.20250314.001.

[4] Katz E, Lazarsfeld P F, Roper E. Personal influence: The part played by people in the flow of mass communications[M]. Routledge, 2017.

[5] Noelle-Neumann E. The spiral of silence a theory of public opinion[J]. Journal of communication, 1974, 24(2): 43-51.

[6] 张智鹏.在批判与经验之间：格伯纳培养理论的范式接合与实证扦格[J].新闻与传播研究,2024,31(8)34-49+126-127.

[7] 张志成.社会建构论视阈下数据现实与数据新闻生产的建构[J].新闻传播,2020,(8)8-10.

[8] 唐晓波，向坤．基于 LDA 模型和微博热度的热点挖掘[J]. 图书情报工作,2014,58(5)58-63.DOI:10.13266/j.issn.0252-3116.2014.05.010.

[9] 韩忠明，李梦琪，刘雯，等．网络评论方面级观点挖掘方法研究综述[J]. 软件学报,2018,29(2)417-441.DOI:10.13328/j.cnki.jos.005386.

[10] Liu, B. (2012). Sentiment Analysis and Opinion Mining. Morgan & Claypool.

[11] Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? Technological Forecasting and Social Change, 114, 254-280.

[12] 张洋,廖怀远.AI 冲击何以引发职业焦虑?——基于微博用户话语的失业风险感知研究[J].教育传媒研究,2025,(5)66-74.DOI:10.19400/j.cnki.cn10-1407/g2.2025.05.003.

[13] 王玉洁.情绪、传播与个体：AI 素养对焦虑的影响研究——感知拟人性和人机信任的中介作用[J].东南传播,2026,(2)117-121.DOI:10.13556/j.cnki.dncb.cn35-1274/j.2026.02.017.